

Sprawozdanie z zadania: Rozpoznawanie cyfr przy użyciu sieci neuronowej

1. Wstęp

Celem zadania było stworzenie i wytrenowanie sieci neuronowej rozpoznającej cyfry z podanego zbioru danych MNIST przy użyciu biblioteki TensorFlow/Keras. Sieć miała zostać oceniona pod względem współczynnika prawidłowej rozpoznawalności na zbiorze testowym oraz parametrów takich jak czułość i precyzja.

2. Opis implementacji

Implementacja została przeprowadzona w języku Python z użyciem biblioteki TensorFlow. Model został oparty na sieci neuronowej składającej się z następujących warstw:

- Warstwa wejściowa Flatten przekształcająca obraz 28x28 pikseli do jednowymiarowego wektora,
- Warstwa ukryta Dense z 128 neuronami i funkcją aktywacji ReLU,
- Warstwa Dropout o wartości 0.2, aby zapobiec przeuczeniu,
- Warstwa wyjściowa Dense z 10 neuronami (po jednym dla każdej cyfry od 0 do 9).

Do kompilacji modelu użyto:

- Optymalizatora adam,
- Funkcji straty SparseCategoricalCrossentropy,
- Metryki accuracy mierzącej dokładność klasyfikacji.

Model został wytrenowany przez 5 epok na zbiorze treningowym MNIST, po czym dokonano ewaluacji na zbiorze testowym.

3. Wyniki Po przeprowadzeniu treningu i testowania modelu uzyskano następujące wyniki:

- Dokładność na zbiorze treningowym: Ok. 98%
- Dokładność na zbiorze testowym: Ok. 97%

Dobre wyniki świadczą o poprawnym działaniu modelu i jego zdolności do generalizacji.

4. Czułość i precyzja

Aby obliczyć szczegółowe metryki, takie jak czułość i precyzja dla każdej klasy, wykorzystano funkcję `classification_report` z biblioteki `sklearn.metrics`:

Dzięki temu uzyskano szczegółową ocenę klasyfikatora dla każdej cyfry od 0 do 9. Przykładowe wyniki:

- Czułość (recall): Średnio około 97%, oznacza to, że model poprawnie identyfikuje większość cyfr.
- Precyzja (precision): Średnio około 97%, co oznacza, że model rzadko klasyfikuje błędnie cyfry.

Czym różni się czułość od precyzji?

- Czułość (recall) – określa, jak wiele rzeczywistych pozytywnych przypadków zostało poprawnie sklasyfikowanych przez model. Im wyższa czułość, tym mniejsza liczba pominiętych przypadków pozytywnych.
- Precyzja (precision) – określa, jak wiele przewidywanych pozytywnych przypadków faktycznie jest poprawnych. Wysoka precyzja oznacza, że model rzadko popełnia błędy w postaci fałszywie pozytywnych klasyfikacji.

Obie metryki są istotne dla oceny klasyfikatora, jednak ich znaczenie zależy od kontekstu. W przypadku rozpoznawania cyfr ważne jest zachowanie równowagi między nimi, aby uniknąć zarówno błędnych klasyfikacji, jak i pominięć.

5. Wnioski

Zaprojektowana sieć neuronowa skutecznie rozpoznaje cyfry ze zbioru MNIST. Model osiągnął wysoką dokładność zarówno na zbiorze treningowym, jak i testowym. Dalsza poprawa wyników mogłaby obejmować zwiększenie liczby epok, dodanie kolejnych warstw ukrytych lub zastosowanie metod augmentacji danych. Wyniki metryk czułości i precyzji potwierdzają, że model radzi sobie dobrze z klasyfikacją cyfr.